

MarginGuard: o motor calcula, a IA explica.

Arquitetura, fluxo de execução, ferramentas determinísticas e governança do agente de diagnóstico de margem da Vértice Retail.

O QUE ESTE DOCUMENTO DESCREVE	COMO FOI GERADO	MARCAS DE CONFIANÇA
O sistema que responde perguntas de margem sobre a base da Vértice Retail sem deixar o modelo de linguagem calcular nada. Todo número citado veio de uma função Python executada sobre os CSVs.	Os números são lidos do sistema no momento da geração: 39 ferramentas vêm do registro do motor, a contagem de testes vem dos arquivos de teste e a seção 15 é uma execução real.	● fato calculado ● estimativa sob premissa ○ direção sem valor

1. Visão geral

Problema de negócio. A Vértice Retail cresceu receita sem que a margem de contribuição acompanhasse. O diagnóstico precisa dizer onde a margem se perde, quanto vale cada frente e o que é recuperável — separando o que é fato apurado do que é estimativa sob premissa.


Objetivo do agente. Responder perguntas de margem com número rastreável, recorte declarado e força de evidência explícita, de forma que um comitê possa decidir sobre a resposta sem refazer a conta.

Papel da IA. Interpretar a pergunta, escolher a ferramenta e redigir. A IA não calcula, não estima e não preenche lacuna de dado. Quando a pergunta não se sustenta nos dados, a resposta é uma recusa medida, com a lacuna nomeada.

Escopo. Margem, desconto, frete, devolução, cancelamento, pendência, atendimento e sazonalidade, sobre os cinco CSVs do case. Fora de escopo: qualquer afirmação sobre cliente individual, LTV, CAC e churn — os campos de cliente não reconciliam com a transação (premissa P8).

2. Arquitetura

Seis camadas entre a pergunta e a resposta, com uma regra atravessando todas.



O motor (vertice/engine/) não importa nada do agente: é usável sozinho, sem chave de API e sem rede.

FIGURA 1 · CAMADAS DO MARGIN GUARD, DA PERGUNTA À RESPOSTA

3. Fluxo de execução

01	02	03	04	05
Roteamento	Investigação	Síntese	Verificação	Trace
Regra em Python classifica a intenção. Rota determinada executa direto.	Pergunta aberta entra no laço ReAct: ação, execução, observação.	O modelo redige no contrato de quatro seções, só com números devolvidos.	Número sem lastro nas ferramentas bloqueia a publicação.	Execução inteira gravada em JSON e consultável pela API.

4. Router determinístico

O roteador existe para tirar do modelo a decisão de o que perguntar aos dados. Devolve um objeto [Roteamento](#) inspecionável, não um texto para outra regex interpretar.

CAMPO	O QUE CARREGA
intencao	a classe da pergunta (ex.: APLICAR_DESCONTO)
ferramenta	qual função do motor executar, ou None
parametros	canal, categoria, percentual, período já extraídos
confianca	quanto a regra casou, de 0 a 1
faltando	parâmetros que a pergunta não trouxe
motivo	por que esta rota foi escolhida — texto legível

Quando falta parâmetro obrigatório, a rota não é considerada determinada e o agente pergunta em vez de assumir um valor. É o que impede o sistema de inventar um teto de desconto que ninguém pediu.

5. Agente ReAct

Usado quando a pergunta é aberta — "por que a margem caiu?", "qual a prioridade?" — e o roteador não consegue determinar uma única ferramenta.

O protocolo é de texto: o modelo responde [AÇÃO:](#) e [PARÂMETROS:](#), o parser lê, o motor executa e devolve a observação. O laço tem teto de iterações e fallbacks para resposta malformada, ferramenta inexistente e chamada repetida.

6. Ferramentas

39 ferramentas registradas por decorador em [vertice/engine/registry.py](#). Cada uma declara prompt, schema e parâmetros, e devolve o recorte aplicado, a premissa e a marca de confiança.

39	10	457	12	5
FERRAMENTAS	FAMÍLIAS	FUNÇÕES DE TESTE	PREMISSAS	CSVs DO CASE

RENTABILIDADE E MARGEM · 4 FERRAMENTAS

FERRAMENTA	O QUE FAZ
comparar_periodos	Compara margem entre dois períodos e decompõe a variação de margem% em contribuição de desconto, custo e frete.
margem_consolidada	Margem de contribuição de toda a base aprovada: receita bruta, desconto, custo, frete, margem em R\$ e %, com decomposição MECE.
margem_na_janela	Margem da janela mais recente (padrão 7 dias) contra a janela anterior de mesmo tamanho.
margem_por_dimensao	Margem aberta por uma dimensão, ordenada.

DESCONTOS E SIMULAÇÃO DE TETO · 5 FERRAMENTAS

FERRAMENTA	O QUE FAZ
cenarios_reducao_desconto	Cenários conservador / base / agressivo de redução do desconto no grupo acima de um limiar (padrão 25%).
simular_desconto_em_segmento	Aplica um desconto hipotético a um recorte (canal, mês, categoria) e devolve o efeito na margem do segmento e na consolidada.
simular_reajuste_preco	Simula um reajuste de preço em um recorte e devolve o efeito na margem do segmento e na consolidada.
simular_teto_desconto	Impõe um teto: todo pedido com desconto acima do teto passa a receber exatamente o teto.
tabela_faixas_desconto	Itens por pedido, ticket médio e margem por faixa de desconto (0%, 0–10%, 10–20%, 20–25%, 25–30%, 30%+).

POLÍTICA DE DESCONTO E ALÇADAS · 2 FERRAMENTAS

FERRAMENTA	O QUE FAZ
consultar_politica_desconto	Diz se um desconto está dentro da política e quem precisa aprovar.
pedidos_acima_do_teto	Conta pedidos que excedem o teto e mede dois sinais de contorno da política, incluindo concentração logo abaixo do teto.

FRETE E ASSIMETRIA POR CANAL · 4 FERRAMENTAS

FERRAMENTA	O QUE FAZ
custo_assimetria_frete	Quantifica quanto um canal paga em frete que não pagaria se seguisse a mesma regra dos demais.
dispersao_componentes_entre_canais	Coefficiente de variação de frete%, desconto% e custo% entre os canais.
politica_frete_por_canal	Mapeia a política efetiva de cada canal: % de pedidos com frete grátis, frete médio, frete como % da receita.
regra_frete_por_limiar	Quanto um canal deixaria de pagar se seguisse a regra objetiva dos demais: frete só em pedidos abaixo de um limiar.

PERDA DEPOIS DO PEDIDO · 2 FERRAMENTAS

FERRAMENTA	O QUE FAZ
pendencias_antigas	Pedidos em "Aguardando" há mais de N dias e a margem não confirmada que carregam.
perda_pos_pedido	Ponte entre a margem calculada e a que se realiza: quanto se perde depois que o pedido é registrado.

DEVOLUÇÕES, ROAS E MARGEM NEGATIVA · 3 FERRAMENTAS

FERRAMENTA	O QUE FAZ
impacto_devolucoes	Vazamento de margem por devolução — o último componente do MECE (Receita – Desconto – Custo – Frete – Devolução).
pedidos_margem_negativa	Pedidos que destroem margem: $\text{margem_contribuicao} < 0$.
ranking_roas_canais	Ranking relativo de eficiência de marketing por canal (mediana de ROAS e CAC).

SAZONALIDADE · 2 FERRAMENTAS

FERRAMENTA	O QUE FAZ
indice_sazonalidade	Índice sazonal por mês = $\text{volume do mês} \div \text{volume médio mensal}$ (>1 = mês acima da média).
tendencia_ajustada_sazonalidade	Tendência de uma métrica percentual com regressão linear sobre o tempo, informando se a inclinação é significativa.

VALIDAÇÃO ESTATÍSTICA · 5 FERRAMENTAS

FERRAMENTA	O QUE FAZ
anova_um_fator	Testa se a média de uma métrica difere entre todos os níveis de uma coluna categórica.
classificar_evidencia	Classifica a força da evidência (FORTE / MODERADA / FRACA) por critério objetivo de p, R^2 e n.
qui_quadrado_independencia	Independência entre duas colunas categóricas (ex.: canal × frete_gratis).
regressao_linear_multipla	Regressão OLS de uma métrica sobre variáveis explicativas numéricas.
teste_t_welch	Teste t de Welch comparando uma métrica entre dois grupos de uma coluna categórica.

AUDITORIA DE QUALIDADE DE DADO · 9 FERRAMENTAS

FERRAMENTA	O QUE FAZ
checar_completude	Percentual de nulos por coluna, do mais incompleto para o menos.
checar_devolucao_fora_prazo	Devoluções aceitas fora do prazo legal de arrependimento (CDC).
checar_duplicatas_chave	Linhas cuja coluna-chave aparece mais de uma vez (ex.: order_id repetido).
checar_faixa_implausivel	Valores fora de uma faixa esperada informada por quem conhece o negócio.
checar_integridade_referencial	Valores de chave estrangeira sem correspondência na tabela de origem.
checar_outliers_iqr	Registros fora de $Q1 - m \cdot IQR / Q3 + m \cdot IQR$ (padrão $m = 3,0$, outlier severo).
coerencia_motivo_entrega	Testa se "Atraso na entrega" é coerente com o tempo de entrega registrado.
relatorio_auditoria_dados	Roda de uma vez todas as checagens determinísticas de qualidade sobre as bases do case.
verificar_consistencia_categorica	Tabela de contingência entre duas colunas categóricas — revela combinação sem sentido de negócio.

COBERTURA DE DADOS E KPIS · 3 FERRAMENTAS

FERRAMENTA	O QUE FAZ
cobertura_de_dados	Responde se uma pergunta é sustentável pelos dados antes de tentar respondê-la.
caso_base_do_plano	Soma as alavancas com valor defensável e separa o que está sob controle interno do que depende de terceiros.
kpis_do_teto	KPIs de aceite de um teto de desconto: taxa atual e esperada, regra de parada e ponto de equilíbrio.

7. Motor determinístico

Todo cálculo financeiro e estatístico é Python sobre pandas e scipy: margem, decomposição MECE, simulação de teto, regra de frete, ponte do pós-pedido, teste t de Welch, qui-quadrado, regressão e sazonalidade.

Por que não no prompt. Um modelo de linguagem não é reprodutível entre execuções, não declara a premissa que usou e não tem como ser auditado número a número. Os 457 testes deste projeto verificam funções Python; não haveria como testar aritmética feita dentro de um prompt.

8. Verificação numérica

[verificacao.py](#) coleta todos os números que as ferramentas devolveram na execução e confere cada número do texto final contra esse conjunto. Número que não aparece em nenhum resultado bloqueia a publicação da resposta.

9. Trace e auditoria

Cada execução grava um JSON em [traces/](#) com pergunta, cada ação, os parâmetros, o resultado bruto de cada ferramenta e a resposta final. A API expõe `GET /api/trace/{id}`, e o painel liga a resposta ao trace que a produziu.

10. Dados

Cinco CSVs em [data/](#): vendas, clientes, estoque, marketing e atendimento. A janela vai de 01/01/2023 a 26/01/2024.

ACHADO NA BASE	CONSEQUÊNCIA
11,73% da receita bruta nunca foi recebida	métricas financeiras usam só status Aprovado (P1)
346 clientes distintos em vendas contra 15.000 no cadastro	LTV, CAC e segmentação não se ligam à transação (P8)
marketing.receita_gerada com atribuição sobreposta	nunca usada para valor em R\$ (P2)
684 registros de "Tamanho errado" em categoria sem grade	motivo de devolução não é tratado como causa (P9)
margem de contribuição é anterior à devolução	devolução é vazamento adicional, não descontado (P7)

11. Premissas

As 12 premissas estão numeradas em [PREMISSAS.md](#) e são citadas pelo código nos pontos onde valem.

P1	Só status_pagamento == 'Aprovado' é receita real	P7	margem_contribuicao é anterior à devolução
P2	marketing.receita_gerada não vira valor em R\$	P8	Margem negativa não é outlier a limpar
P3	A identidade contábil é sanidade, não causa raiz	P9	Uma linha vazia descartada
P4	Desconto × volume é correlação, não causalidade	P10	Encoding
P5	Toda simulação assume volume constante	P11	O recorte da simulação é parâmetro declarado
P6	Sazonalidade e mês parcial	P12	Margem tem dois denominadores, e os dois viajam juntos

12. Limitações

O que o sistema não afirma, e por quê:

Elasticidade de desconto. Os dados são observacionais, sem grupo de controle nem variação exógena. Toda simulação de teto assume volume constante e diz isso no retorno.

Meta em reais para o pós-pedido. A base não registra destino do item devolvido, custo da logística reversa nem motivo validado. A perda é dimensionada, não convertida em meta.

Teste A/B por cliente. O cálculo de poder mostra que medir perda de volume exigiria 887.164 clientes; a base tem 331. A inviabilidade é medida pelo próprio instrumento, não suposta.

Cliente individual. Fora de escopo por P8.

13. Governança

POLÍTICA DE DESCONTO

Proposta com estado persistido, dono e data em cada transição. O fluxo vai de Rascunho a Simulação e congela: aprovar de verdade exige identidade autenticada. A regra de que quem propõe não aprova já é testada.

LIMITES DO AGENTE

O agente lê; não escreve na base. Nenhuma rota grava em data/* .csv.

TRATAMENTO DE INCERTEZA

Toda resposta declara força de evidência (FORTE, MODERADA ou FRACA) com o critério estatístico que a sustenta e a principal limitação.

RASTREABILIDADE

Trace por execução, hash da base em todo resultado e recorte declarado em todo valor em reais.

14. Testes

457 funções de teste, que geram 925 casos com parametrização. A suíte roda sem rede e sem chave de API.

test_agente.py	119	test_api.py	46	test_motor.py	36	test_router.py	33
test_auditoria.py	29	test_perguntas_negocio.py	29	test_relatorio_e_card.py	29	test_verificacao.py	29
test_politica.py	25	test_aceite_livro.py	22	test_experimento.py	16	test_filtros.py	12
test_prompts.py	12	test_integridade_dados.py	9	test_config.py	7	test_roteamento_deck.py	4

Testes de aceite. [test_aceite_livro_de_numeros.py](#) confere, ID a ID, se o motor reproduz os números publicados no Livro de Números — o teto de 20%, a regra de frete, a ponte do pós-pedido e os KPIs do roadmap. Se um falhar, o motor divergiu da apresentação, e isso é decisão humana, não ajuste de teste.

15. Exemplo ponta a ponta

Execução real, gerada no momento em que este documento foi produzido.

PERGUNTA

O que acontece se aplicarmos 17% de desconto em Moda no Email Marketing?

ROTEADOR

Intenção	APLICAR_DESCONTO
Ferramenta	simular_desconto_em_segmento
Parâmetros	17,0% · Email Marketing · Moda
Confiança	0.95
Motivo	verbo de aplicação + percentual explícito

RESULTADO DO MOTOR

Pedidos no segmento	843 · 3,45%
Receita bruta	R\$ 604.612,32
Desconto atual	7,17% · R\$ 43.339,85
Simulado a 17%	R\$ 102.784,09
Variação · marca	R\$ 59.444,24 📉

LEITURA · PERÍODO 2023-01-01 A 2024-01-26 (13 MESES ACUMULADOS)

Aplicar 17% neste segmento aumentaria o desconto concedido em R\$ 59.444,24, porque o desconto que já se pratica ali é de 7,17%. O número é cenário sob premissa de volume constante, não previsão — e é a própria ferramenta que declara isso no campo de premissa.

16. Estrutura do projeto

```
vertice-retail/
├─ data/          cinco CSVs do case (entrada; nunca reescritos)
├─ vertice/       motor + agente + API
│  └─ engine/     39 ferramentas determinísticas, sem LLM
│     └─ agent/    router, ReAct, verificação, trace, prompts
├─ frontend/      painel web estático (sem framework, sem build)
├─ tests/         457 funções de teste
├─ scripts/       auditoria das 95 perguntas e geração deste PDF
├─ design-system/ tokens de marca (procedência do visual)
├─ docs/          como rodar e relatório das 95 perguntas
├─ documentacao/  este documento
├─ README.md      arquitetura e decisões
└─ PREMISSAS.md   as 12 premissas, numeradas
```

17. Execução

Passo a passo em Linux/WSL, da instalação ao painel web.

Todos os comandos partem da raiz do repositório — a pasta que contém requirements.txt.

1. PRÉ-REQUISITO DO SISTEMA (UMA VEZ)

```
sudo apt update
sudo apt install -y python3 python3-venv python3-pip
```

2. ENTRAR NO PROJETO

```
cd /mnt/c/caminho/para/vertice-retail
```

No WSL, o disco do Windows fica sob `/mnt/c/`.

3. CRIAR E ATIVAR O AMBIENTE VIRTUAL

```
python3 -m venv venv  
source venv/bin/activate
```

4. INSTALAR AS DEPENDÊNCIAS

```
pip install -r requirements.txt
```

5. VERIFICAR — SEM REDE E SEM CHAVE DE API

```
python -m pytest
```

Esperado: 925 passando, 11 pulados. Este passo não usa internet: o motor lê os CSVs e calcula em Python. É a verificação que precede qualquer demonstração.

```
python -m pytest tests/test_aceite_livro_de_numeros.py -v
```

Os 35 testes de aceite conferem, ID a ID, se o motor reproduz os números publicados. É o "Passo 0" da demonstração.

6. USAR SÓ O MOTOR, SEM IA

```
python -c "from vertice.engine import executar; import json; \  
    print(json.dumps(executar('simular_teto_desconto', {'teto_pct': 20}), \  
        ensure_ascii=False, indent=2))"
```

7. AGENTE SEM CHAVE (MODO MOCK)

```
python -m vertice.cli --mock
```

O texto vem de roteiro fixo; os números são reais, porque o motor roda de verdade.

8. AGENTE COMPLETO (PRECISA DE CHAVE)

```
export ELOAGENTS_API_KEY="sua-chave"  
python -m vertice.cli --diagnostico # confere conexão e modelos  
python -m vertice.cli # sessão interativa
```

9. PAINEL WEB

```
python -m vertice.api # http://localhost:8000  
VERTICE_API MOCK=1 python -m vertice.api # sem chave nenhuma
```

EQUIVALENTE EM WINDOWS (POWERSHELL)

```
py -m venv venv
venv\Scripts\Activate.ps1
pip install -r requirements.txt
python -m pytest
$env:ELOAGENTS_API_KEY = "sua-chave"
python -m vertice.api
```